

02. 도함수 , 경사도

(derivate)



일변량

(기울기, gradient)



다변량

최적화와 도함수


- 최적화

크게 하게 위해서는 부호만 바꿔주면 OK

- 목적함수의 값을 작게 하는 계 획적 탐색 문제 계 획점 (design point) 작 기
- 값을 변화시킬 때, 목적함수 값의 변화 (목적함수 값 작 게 하는 결 택)
- 도함수 / 경사도 → x의 변화에 따른 목적함수 f의 변화 측정

- 도함수

- 접선 (tangent line)
- 도함수 : 접선의 기울기



접선의 기울기 = 0 ⇒ 최소점



- 선형 근사 (linear approximation)

$$f(x+\Delta x) \approx f(x) + f'(x) \Delta x$$

ex) $f(x) = x^2$, $f'(x) = 2x$, $x = -1$, $\Delta x = 0.01$

→ -1에서 -0.99로 이동할 때 함수값 변화 보고 싶음.
→ 목적함수 값 얼마나 변화?

$$f(-1+0.01) \approx f(-1) + f'(-1) \times 0.01$$

$$0.9801 \approx 1 + (-2) \times 0.01$$

↑ 기울기 0이 되면 목적함수 값이 줄어드는지
그곳이 design point. (계획점, minimizer)

가울기를 $f'(x)$ 이용해 직접 적용

선형 근사

- $f(x) = x^2$
- $f(x+dx) = f(x) + f'(x)dx$
- dx는 델타 x 의미한다

```
x=-1
dx=0.001

f=x**2
df=d2*x → 1차 미분한 도함수

f_dx=f+df*dx
print('f값, f_dx값')
print((f,f_dx)) → 값값 (1)에 2차항 (0.998), dx작아질 수록 값값에 가까워짐.

print(' ')
print('dx 값 변화에 따른 f값과 f_dx값')
for dx in [1E-3,1E-4,1E-5,1E-6]:
    f_dx=f+df*dx
    print((f,f_dx))

print(' ')
print('f(-1)값')
def f(x):
    return x**2
print(f(-1))

print(' ')
print('df(-1)값')
def df(x):
    return 2*x
print(df(-1))

print(' ')
print('dx 값 변화에 따른 f(-1), f_dx(-1,dx), 두 값의 차이 절대값')
def f_dx(x,dx):
    return f(x)+df(x)*dx
for dx in [1E-3,1E-4,1E-5,1E-6]:
    print('%4f, %4f (%4f)' % (f(-1),f_dx(-1,dx),abs(f(-1)-f_dx(-1,dx))))
```

↑ 1차 미분한 $x=-1$ 에서의 도함수. 기울기 = -2
 $x=-1$ 일 때 x^2 함수의 탄젠트 라인 기울기 -2
 ↗ 값값에 가까운 값으로 수렴

```
f값, f_dx값
(1, 0.998)

dx 값 변화에 따른 f값과 f_dx값
(1, 0.998)
(1, 0.9998)
(1, 0.99998)
(1, 0.999998)

f(-1)값
1

df(-1)값
-2


dx 값 변화에 따른 f(-1), f_dx(-1,dx), 두 값의 차이 절대값
1.0000, 0.9998 (0.0002)
1.0000, 0.9998 (0.0002)
1.0000, 1.0000 (0.0000)
1.0000, 1.0000 (0.0000)
```

도함수 정의

1) Lagrange


$$f(x + \Delta x) \approx f(x) + f'(x) \Delta x$$

$$\rightarrow f'(x) \equiv \frac{f(x+\Delta x) - f(x)}{\Delta x} = \frac{\Delta f(x)}{\Delta x}$$



2) Leibniz

$$f'(x) \equiv \frac{d f(x)}{d x} \quad \text{단, } d = f(x+\Delta x) - f(x)$$




도함수의 극한 ($h \rightarrow 0$)

- h : 차분 값 (step size)

- 전방 차분 (forward difference)

$$f'(x) \equiv \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$


→ 계산적으로 정의식 직접 이용 무리 (why? 분모 = 0)



- 후방 차분 (backward difference)

$$f'(x) \equiv \lim_{h \rightarrow 0} \frac{f(x) - f(x-h)}{h}$$

↓



후방 차분 값 = 전방 차분 값 → continuous function

만약, 후방 차분 ≠ 전방 차분 → 도함수 존재 X = 미분값 존재 X

⇒ 최적화에서 대부분 목적함수는 연속함수이다.

- 중심 차분 (central difference)

: 양쪽에서 step-size 동일한 값으로 지점해 도함수 도출

$$f'(x) \equiv \lim_{h \rightarrow 0} \frac{f(x+\frac{h}{2}) - f(x-\frac{h}{2})}{h}$$

다차원 도함수

- 경사도 (가울기, gradient)

• 일차원 도함수의 다차원에서의 일반화.

: 한 점에서 어떤 방향으로 조금 변화시켰을 때, 함수값의 변화를

예측할 수 있는 함수의 곡소 가울기.

• 경사점 (gradient point)

: 초평면 (hyperplane) 상의 가장 경사가 큰 방향에 있는 점

- 초평면

$$w_1 x_1 + w_2 x_2 + \dots + w_n x_n = b$$


→ 변수가 3개면 4차원 공간 상에서의 hyperplane 정의

• 임의의 vec $W = [w_1 \ w_2 \ \dots \ w_n]$

• 임의의 scalar b

$$[a, b, c] = [a \ b \ c]^T$$

• $(n-1)$ 차원



dim 2의 평면 어떻게 정의? → $w_1 x_1 + \dots + w_n x_n = b$ 정의

$$\therefore w_1 x_1 + w_2 x_2 = b$$

다차원 도함수

- 경사도

- $\nabla f(x)$: 함수 f 의 점 x 에서의 경사도. $(n \times 1)$ 벡터
 - $\frac{\partial f(x)}{\partial x_i}$: 함수 f 에 대한 변수 x_i 의 편미분 값. \neq 미분
- $\Rightarrow \nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n} \right]$

ex) $C = [2, 0]$ 에서의 $f(x) = x_1 \cdot \sin(x_2) + 1$ 의 경사도

$$\begin{aligned} \nabla f(x) &= \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2} \right] \\ &= [\sin(x_2), x_1 \cdot \cos(x_2)] \\ \nabla f(C) &= [0, 2] \end{aligned}$$

- 헤세 행렬 (Hessian)

: 함수의 2차 곡률 (local curvature)에 대한 정보

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(x)}{\partial x_n \partial x_n} \end{bmatrix}_{n \times n}$$

\rightarrow 다변량 최적분석에서, 최소 제곱 추정량 계산 위해 필요.

대각 원소 중심으로 비대각 원소 대칭 (대칭 행렬)

0보다 크거나 작는지 확인해 곡률 파악.

But, 최근 최적화 문제 2차 미분 사용 x . 1차 미분 정보 이용.

다차원 도함수

다변량 함수에서도 gradient 존재 (조평면, 움직일 수 있는 방향 ∞)

- 방향 도함수 (directional derivative)

- $\nabla_S f(x)$: 점 x 를 속도 S 로 움직였을 때의 $f(x)$ 변화율
 - 전방 차분 : $\nabla_S f(x) \equiv \lim_{h \rightarrow 0} \frac{f(x+hs) - f(x)}{h}$
- $\rightarrow x$: n 개의 원소로 구성된 vec
 $\rightarrow S$: 방향 vec, $n \times 1$

- 후방 차분 : $\nabla_S f(x) \equiv \lim_{h \rightarrow 0} \frac{f(x) - f(x-hs)}{h}$
- \Rightarrow 전방 차분 = 후방 차분 이면, $f(x)$ 는 연속

- 중심 차분 : $\nabla_S f(x) \equiv \lim_{h \rightarrow 0} \frac{f(x+\frac{h}{2}s) - f(x-\frac{h}{2}s)}{h}$

$$\nabla_S f(x) = \nabla f(x)^T \cdot S$$

ex) 점 $x = [1, 0]$ 에서 방향 $S = [-1, -1]$ 로의 함수

$f(x) = x_1 \cdot x_2$ 의 방향 도함수

$$\nabla f(x) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2} \right] = [x_2, x_1]$$

$$\nabla_S f(x) = \nabla f(x)^T S = [0 \ 1] \begin{bmatrix} -1 \\ -1 \end{bmatrix} = -1$$

\perp 함수 f 값이 적어지는 방향으로 움직인다.

* 경사점

: 방향으로 가는 것 중, 기울기가 가장 가파르게 되는 방향

* 계획점 찾는 것이 목적!

다차원 도함수

- 수치 미분 (numerical differentiation)

- : 매우 작은 h에 대한 유한 차분 방법 h(step size) adam으로 매우 작은 값 미리 정하기
- 전방 차분법 : $f'(x) \approx \frac{f(x+h) - f(x)}{h}$
 - 후방 차분법 : $f'(x) \approx \frac{f(x) - f(x-h)}{h}$
 - 중심 차분법 : $f'(x) \approx \frac{f(x+\frac{h}{2}) - f(x-\frac{h}{2})}{h}$ < 99 사용 >

수치미분

- 전방차분
- 후방차분
- 중심차분

```
# 전방차분
def forward_diff(f, x, h=1E-6):
    df = (f(x+h) - f(x)) / h
    return df
print('전방차분시 x=-1값')
print(forward_diff(f, -1))
print(' ')

# 후방차분
def backward_diff(f, x, h=1E-6):
    df = (f(x) - f(x-h)) / h
    return df
print('후방 차분시 x=-1값')
print(backward_diff(f, -1))
print(' ')

# 중심차분
def central_diff(f, x, h=1E-6):
    df = (f(x+0.5*h) - f(x-0.5*h)) / h
    return df
print('중심차분시 x=-1값')
print(central_diff(f, -1))
print(' ')

print('h값 변화에 따른 df(-1)값, 중심차분 값, 차이의 절댓값')
for h in [1E-4, 1E-6, 1E-8]:
    cf = central_diff(f, -1, h)
    print('df: %.8f, cf: %.8f' % (df(-1), cf, abs(df(-1) - cf)))
print(' ')
# Step size(h)를 작게 하거 : 1E-8에서 오차 증가. 무조건 작다고 좋겠지 X
```

↳ x*은 0에서 회저, 0에 가까워지!
중심차분 값 0에 가까워 지며 함값과 차이 X, 기울기=0 이 되는 점

```
전방차분시 x=-1값
-1.999999900079633

후방 차분시 x=-1값
-2.0000000999249673

중심차분시 x=-1값
-2.0000000000575113

h값 변화에 따른 df(-1)값, 중심차분 값, 차이의 절댓값
df: -2.000000000, cf: -2.000000000 (0.000000000)
df: -2.000000000, cf: -1.000000000 (0.000000000)
df: -0.500000000, cf: -0.500000000 (0.000000000)
df: -0.020000000, cf: -0.020000000 (0.000000000)
df: -0.000002000, cf: -0.000002000 (0.000000000)
```


다차원 도함수

- 자동 미분 (Automatic differentiation)

- : AI, DL 알고리즘, gradient 계산, 복잡한 다변량 목적함수 → 자동미분
- 연쇄 법칙 (chain rule) ← 복잡한 함수 간단히 미분
- $$\frac{d}{dx} f(g(x)) = \frac{d}{dx} (f \circ g)(x) = \frac{df}{dg} \cdot \frac{dg}{dx}$$

ex) $f(a,b) = \ln(ab + \max(a,2))$

$$\begin{aligned} \frac{\partial f}{\partial a} &= \frac{\partial}{\partial a} \ln(ab + \max(a,2)) \\ &= \frac{1}{(ab + \max(a,2))} \cdot \frac{\partial}{\partial a} (ab + \max(a,2)) \\ &= \frac{1}{(ab + \max(a,2))} \left[\frac{\partial (ab)}{\partial a} + \frac{\partial (\max(a,2))}{\partial a} \right] \\ &= \frac{1}{(ab + \max(a,2))} \left[(b \cdot \frac{\partial a}{\partial a} + a \cdot \frac{\partial b}{\partial a}) + \left(\frac{\partial a}{\partial a} (2 > a) + \frac{\partial a}{\partial a} (2 < a) \right) \right] \\ &= \frac{1}{(ab + \max(a,2))} [b + (2 < a)] \end{aligned}$$



- 전방 누적법 (forward accumulation) → 간단한 문제를 복잡한 문제로 바꿔 가는 것.

$$\begin{aligned} \frac{df}{dx} &= \frac{df}{dC_4} \cdot \frac{dC_4}{dx} = \frac{df}{dC_4} \left(\frac{dC_4}{dC_3} \cdot \frac{dC_3}{dx} \right) \\ &= \frac{df}{dC_4} \left(\frac{dC_4}{dC_3} \left(\frac{dC_3}{dC_2} \cdot \frac{dC_2}{dx} + \frac{dC_3}{dC_1} \cdot \frac{dC_1}{dx} \right) \right) \end{aligned}$$

⇒ 계산 그래프 : $\dot{a} = \frac{\partial a}{\partial a}$, $\dot{b} = \frac{\partial b}{\partial b}$

