

07. 시스템 with Sympy

- Symbolic differentiation

: 매번 도함수나 gradient 함수를 통해서 지정 번거로운
파이썬에서 자동적으로 수행해주는 모듈

→ Symbolic differentiation 이용해서

Backtracking line search, Strong backtracking 구현

Local Descent (더변량)은 backtracking / Strong backtracking

이용해 step-size 결정할 다음, 최적화

• Univariate

ex) $f(x) = \exp(x-2) - x \rightarrow$ 함수값, 도함수 값 계산

```
# Example 3.1 : univariate
x=sp.Symbol('x') #심볼로 사용하게 될 변수 선언. x는 변수가 아니라 기호로 인식
f=sp.exp(x-2)-x #sp.exp는 계산 수행함수 아니라 심볼로 처리
df:=diff(x) #라는 sympy 함수를 이용. 심볼 x를 통해서-
print('df:',df)

# 함수 값 계산
derv=sp.lambdify(x,df,'numpy') #x, df: symbol
print('derv(1): ',derv(1)) #계산된 도함수 값 나옴
print('derv(2): ',derv(2))
print('derv(3): ',derv(3)) #지수 값이 양수되면 계산된 도함수 값 급격한 증가

df:= exp(x - 2) - 1
derv(1): -0.6321205588285577
derv(2): 0.0
derv(3) 1.718281828459045
```

• multivariate

ex) $f(x_1, x_2) = x_1^2 + x_1 x_2 + x_2^2$

```
# Example 4.2 : p.58
def f(x):
    y=x[0]**2+x[0]*x[1]+x[1]**2
    return y

x=sp.IndexedBase('x')
print('x[0]에 대한 f(x) 편미분: ',sp.diff(f(x),x[0])) # x[0]에 대한 f(x)편미분
print('x[1]에 대한 f(x) 편미분: ',sp.diff(f(x),x[1])) # gradient 얻기 위해 2개의 편미분 값 필요
print('두 편미분 합치기: ',sp.diff(f(x),x[i]) for i in range(2))

gradients=np.array([sp.diff(f(x),x[i]) for i in range(2)])
grads=sp.lambdify(x,gradients,'numpy')

x_=[1,2]
print(grads(x_))

x[0]에 대한 f(x) 편미분: 2*x[0] + x[1]
x[1]에 대한 f(x) 편미분: x[0] + 2*x[1]
두 편미분 합치기: 2*x[0] + x[1], x[0] + 2*x[1]
[4, 5]
```

Local Descent Algorithm 확인

- Local Descent Algorithm

① $x^{(k)}$ 종료 조건 확인 : k번째 반복

② descent direction, $d^{(k)}$ 결정

③ $\alpha^{(k)}$ 결정 : 결정된 direction 이용해 α 계산

④ $x^{(k+1)} = x^{(k)} + \alpha^{(k)} \cdot d^{(k)}$: 계획점 이동

→ 이 과정 반복해 backtracking line search로 step-size
구해 최소값 구할 수 있음.

cf. Step 1에서의 종료 조건: Termination Condition

1. abstol : $|y - y_{prev}| < 1E-8$

2. reltol : $|y - y_{prev}| < 1E-8 \times (|y_{prev}| + 1E-8)$

3. maximum iteration : over flow 위험으로 반복수 지정

```
# 종료 조건 : abstol
x_ = np.array([1,2]) #1번 스텝
d_ = -1*np.array(grads(x_)) #2번 스텝
alpha=backtracking_line_search(f,grads,x_,d_) #3번 스텝

y_prev=f(x_) #초기값으로 계산된 값

#종료조건을 만족하지않 반복 수행
flag=True #bool 변수 선언
# 이 값이 false일때 종료

i=1
while flag: # 첫번째 계산 수행했으나 무조건 한 번 더 계산 수행
    x_ = x_ + alpha*d_ #4번 단계 : local model 이동
    d_ = -1*np.array(grads(x_))
    alpha=backtracking_line_search(f,grads,x_,d_)
    y_ = f(x_)

    # 종료 할지말지 판단 근거: abstol 이용
    diff=np.abs(y_-y_prev)
    print('alpha,x_,f(x_),diff')

    if diff<1E-8:
        flag=False

    y_prev=y_ #조건 만족 안해낸 비교를 위해 y_prev 지정
    i+=1
```

```
# reltol 종료조건 사용하기!
```

```
x_ = np.array([1,2]) #1번 스텝  
d_ = -1 * np.array(grads(x_)) # 2번 스텝  
alpha = backtracking_line_search(f, grads, x_, d_) # 3번 스텝
```

```
y_prev = f(x_) #초기값으로 계산된 값
```

```
#종료조건을 만족하게끔 반복 수행
```

```
flag = True #bool 변수 선언
```

```
# 이 값이 false일때 종료
```

```
i = 1
```

```
while flag: # 첫번째 계산 수행했으니까 무조건 한 번 더 계산 수행
```

```
    x_ = x_ + alpha * d_ #4번 단계 : local model 이동
```

```
    d_ = -1 * np.array(grads(x_))
```

```
    alpha = backtracking_line_search(f, grads, x_, d_)
```

```
    y_ = f(x_)
```

```
    # 종료 할지말지 판단 근거: abstol 이용
```

```
    diff = np.abs(y_ - y_prev)
```

```
    print(i, alpha, x_, f(x_), diff)
```

```
    if diff < 1E-8 * (np.abs(y_prev) + 1E-8):
```

```
        flag = False
```

```
    y_prev = y_ #조건 만족 안하면 비교를 위해 y_prev 저장
```

```
    i += 1
```

```
# Maximum iteration 사용
```

```
x_ = np.array([1,2]) #1번 스텝
```

```
d_ = -1 * np.array(grads(x_)) # 2번 스텝
```

```
alpha = backtracking_line_search(f, grads, x_, d_) # 3번 스텝
```

```
y_prev = f(x_) #초기값으로 계산된 값
```

```
max_iter = 100
```

```
flag = True #bool 변수 선언
```

```
# 이 값이 false일때 종료
```

```
i = 1
```

```
while flag: # 첫번째 계산 수행했으니까 무조건 한 번 더 계산 수행
```

```
    x_ = x_ + alpha * d_ #4번 단계 : local model 이동
```

```
    d_ = -1 * np.array(grads(x_))
```

```
    alpha = backtracking_line_search(f, grads, x_, d_)
```

```
    y_ = f(x_)
```

```
    # 종료 할지말지 판단 근거: abstol 이용
```

```
    diff = np.abs(y_ - y_prev)
```

```
    print(i, alpha, x_, f(x_), diff)
```

```
    if i > max_iter:
```

```
        flag = False
```

```
    y_prev = y_ #조건 만족 안하면 비교를 위해 y_prev 저장
```

```
    i += 1
```

⇒ backtracking line search 알고리즘 이용 위해

α, β 최적점 결정은 종료조건에 따라 계산 결과 달라짐



목적 함수 값이 어느정도 크기를 갖게끔 계산 됨?

gradient 값의 크기가 어느정도?

α 값이 대체적으로 어떤 값?

에 따라서 종료조건 선택 하기

```
# 함수화 : local descent with backtracking line search
```

```
def local_descent_backtracking(f, grads, x_, alpha=10, TOL=1E-8):
```

```
    d_ = -1 * np.array(grads(x_))
```

```
    alpha = backtracking_line_search(f, grads, x_, d_, alpha)
```

```
    print(alpha, x_, f(x_))
```

```
    y_prev = f(x_)
```

```
    i = 1
```

```
    flag = True
```

```
    while flag:
```

```
        x_ = x_ + alpha * d_
```

```
        d_ = -1 * np.array(grads(x_))
```

```
        alpha = backtracking_line_search(f, grads, x_, d_, alpha)
```

```
        y_ = f(x_)
```

```
        diff = np.abs(y_ - y_prev)
```

```
        print(i, alpha, x_, f(x_), diff)
```

```
        if diff < TOL * (abs(y_prev) + TOL): #종료조건 reltol/사용  
            flag = False
```

```
        y_prev = y_
```

```
        i += 1
```

```
    return i, x_
```

```
x_ = np.array([1,2])
```

```
local_descent_backtracking(f, grads, x_) #메소드 만들어졌음 -> 쉽게 구현
```

Strong-backtracking Algorithm

```
# Algorithm 4.3 : p.82

def strong_backtracking(f, grads, x, d, alpha=1, 0, beta=1E-4, sigma=1E-1):

    y0, g0, y_prev, alpha_prev = f(x), np.dot(grads(x), d), np.nan, 0.0
    alpha_lo, alpha_hi = np.nan, np.nan

    # bracket phase
    while True:
        y = f(x + alpha * d)

        if y > y0 + beta * alpha * g0 or (not(np.isnan(y_prev)) and y >= y_prev):
            alpha_lo, alpha_hi = alpha_prev, alpha
            break
        g = np.dot(grads(x + alpha * d), d)

        if np.abs(g) <= -sigma * g0:
            return alpha
        elif g > 0:
            alpha_lo, alpha_hi = alpha, alpha_prev
            break
        y_prev, alpha_prev, alpha = y, alpha, 2 * alpha

    # zoom phase
    y_lo = f(x + alpha_lo * d)

    while True:
        alpha = 0.5 * (alpha_lo + alpha_hi)
        y = f(x + alpha * d)

        if (y > y0 + beta * alpha * g0) or (y >= y_lo):
            alpha_hi = alpha
        else:
            g = np.dot(grads(x + alpha * d), d)
            if abs(g) <= -sigma * g0:
                return alpha
            elif g * (alpha_hi - alpha_lo) >= 0.0:
                alpha_hi = alpha_lo
            alpha_lo = alpha
```

```
def local_descent_strong_backtracking(f, grads, x_, alpha=10, TOL=1E-8):

    d_ = -1 * np.array(grads(x_))
    alpha = strong_backtracking(f, grads, x_, d_, alpha) #알리지는 부분!
    print(alpha, x_, f(x_))

    y_prev = f(x_)

    i = 1
    flag = True

    while flag:

        x_ = x_ + alpha * d_
        d_ = -1 * np.array(grads(x_))

        alpha = strong_backtracking(f, grads, x_, d_, alpha) #알리지는 부분! alpha(단계값)계산
        y_ = f(x_)

        diff = np.abs(y_ - y_prev)
        print(i, alpha, x_, f(x_), diff)

        if diff < TOL * (abs(y_prev) + TOL): #세가지 종료 조건 이용해 구할 수 있음
            flag = False

        y_prev = y_
        i += 1

    return i, x_
```

```
x_ = np.array([1, 2])
local_descent_strong_backtracking(f, grads, x_)
```