

08. 일차 미분 이용한 방법들

(First-Order Methods)



경사 하강법 (Gradient Descent)

접합 경사하강법 (Conjugate Gradient)

↳ 공액, 켄레

경사 하강법 (Gradient Descent)

- 경사도 : 목적 함수의 1차 미분

- 하강 방향 : d (경사가 큰 방향)

- d 로 이동할 경우, 목적 함수의 최소값으로 계획점 이동
- 목적 함수가 2차 함수의 형태이며, 단계값 충분히 작고 경사도가 '0' 이 아니라는 가정. → 변화 심하지 x

- 경사 하강 방향 : $\nabla f(x)$

- $g^{(k)} = \nabla f(x^{(k)})$, k 번째 반복의 계획점 $x^{(k)}$

- $d^{(k)} = -\frac{g^{(k)}}{\|g^{(k)}\|}$: 표준화 (normalize)

• $d^{(k)}$ 의 길이를 1로 만든다.

• $x^T = [x_1, x_2] \Rightarrow \|x\| = \sqrt{x_1^2 + x_2^2}$ (norm)

- ㉔ gradient Descent 방법은 자료주어진 (surrogate)

목적함수 최소화 문제에 ∇ 사용

방향만 결정되니까 구조 간단, 계산 안정적

- ㉕ 반복식 ∇ 목적 함수 형태에 따라 최적값 얻지 못할

gradient descent 의 특징

↗ : 방향 vec 는 직교!

- 직교성 (orthogonality)

• 직교 : $x^T y = 0 \leftarrow$ 개지고 있는 평면 수 같아야 내적 가능

• $\alpha^{(k)} = \arg \min_{\alpha} f(x^{(k)} + \alpha d^{(k)})$

• $\nabla f(x^{(k)} + \alpha d^{(k)})^T d^{(k)} = 0$

• $d^{(k+1)} = -\frac{\nabla f(x^{(k)} + \alpha d^{(k)})}{\|\nabla f(x^{(k)} + \alpha d^{(k)})\|} \leftarrow$ gradient


• $\nabla f(x^{(k)} + \alpha d^{(k)})^T d^{(k)} = 0 \leftarrow \alpha$ 에 의한 목적함수 최소화값이 되려면 gradient = 0

$\rightarrow d^{(k+1)T} d^{(k)} = -\frac{\nabla f(x^{(k)} + \alpha d^{(k)})^T}{\|\nabla f(x^{(k)} + \alpha d^{(k)})\|} d^{(k)} = 0$

\therefore 두 방향 vec 는 서로 직교성 만족!

↗ 두 vec 의 사이각 90°

ex) Rosenbrock banana function 방향 vec



narrow valley (협곡)

: 천천히 들어들며
최소값에 완만히 이동!

↓

경사하강법은 narrow valley
에서 계산값 불안정해 질수
있다!

ex) $f(x) = x_1 x_2^4$, $x^{(0)} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$

$\nabla f(x)^T = [x_2^4, 4x_1 x_2^3]$

$\nabla f(x) = \begin{bmatrix} -4 \\ -4 \end{bmatrix} = g^{(k)}$

$\|g^{(k)}\| = \sqrt{(-4)^2 + (-4)^2} = 4\sqrt{2}$

$d^{(k)} = \frac{g^{(k)T}}{\|g^{(k)}\|} = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$

접합 경사 하강법 (conjugate Gradient)

최소값이 존재하기 위해서 목적함수의 조건

- FONC : first-order necessary condition

$$f(x^*) \leq f(x+hy) \Leftrightarrow f(x+hy) - f(x^*) \geq 0$$

이차 미분해 테일러 전개 값 이용

테일러 2차 전개

- SONC : second-order necessary condition

$$f(x^*+hy) = f(x^*) + h \nabla f(x^*)^T y + \frac{1}{2} h^2 y^T \nabla^2 f(x^*) y + O(h^3)$$

y는 방향 vec, gradient 값 → 이 값이 0일때 최소점

$$\Rightarrow \frac{1}{2} h^2 y^T \nabla^2 f(x^*) y = f(x+hy) - f(x^*) \geq 0$$

→ FONC, SONC 합침.

- IDEA

2차 형식: quadratic

$$\text{minimize}_x f(x) = \frac{1}{2} x^T A x + b^T x + c$$

• f(x)는 유일한 극소 최소점

• A : 대칭(symmetric)인 양 정칙 (Positive definite) 행렬

• n차원 이차함수는 n번 반복에 의해 최적화.

- 행렬 A에 의한 $d^{(1)}$ 과 $d^{(2)}$ 는 서로 접합(정칙, 공액)

$$: d^{(1)T} A d^{(2)} = 0, \quad \forall i, j \rightarrow \text{반복적 접근} \rightarrow \text{2차 형식 미가!}$$

방향 vec

- 접합 경사 하강 알고리즘

• 접합 방향 : 이전 하강 방향과 경사도 이용해 결정

$$1) d^{(0)} = -g^{(0)}$$

$$2) x^{(2)} = x^{(1)} + \alpha^{(1)} d^{(1)} : \alpha^{(1)} \text{은 선탐색으로 결정}$$

$$k+1) d^{(k+1)} = -g^{(k+1)} + \beta^{(k)} d^{(k)}$$

line search Method
back tracking
Strong backtracking
β^(k)도 찾아내야함 (신호로 유도!)

* 2차 함수이면 α는 계산식 존재

α 찾는 식 찾아 반복계산 X

- 이차 함수의 α

$$\begin{aligned} \text{minimize}_\alpha f(x+\alpha d) & \quad (x-\alpha d)^2 \text{ 형태} \\ \frac{\partial f(x+\alpha d)}{\partial \alpha} &= \frac{\partial}{\partial \alpha} \left[\frac{1}{2} (x-\alpha d)^T A (x-\alpha d) + b^T (x-\alpha d) + c \right] \\ &= d^T A (x-\alpha d) + d^T b \\ &= d^T (Ax+b) - \alpha d^T A d = 0 \end{aligned}$$

$$\therefore \alpha = - \frac{d^T (Ax+b)}{d^T A d} \quad (\text{직접해, 식 이용해 계산})$$

이차 함수 아닐 경우 line search 등의 방법 이용

- β 유도

$$d^{(1)T} A d^{(2)} = 0 \rightarrow d^{(1)} \text{과 } d^{(2)} \text{는 } A \text{는 대칭 \& 양 정칙 행렬}$$

$$\Rightarrow (-g^{(k+1)} + \beta^{(k)} d^{(k)})^T A d^{(k)} = 0$$

$$\Rightarrow -g^{(k+1)T} A d^{(k)} + \beta^{(k)} d^{(k)T} A d^{(k)} = 0$$

$$\Rightarrow \frac{g^{(k+1)T} A d^{(k)}}{d^{(k)T} A d^{(k)}} \rightarrow \text{반복 계산 X, 직접해}$$

A 행렬 파악 불가능해서 단절

- A 선택

• Fletcher-Reeves (1964) : $\beta^{(k)} = \frac{g^{(k)T} g^{(k)}}{g^{(k-1)T} g^{(k-1)}}$


↳ 굳이 A 없어도 됨!

• Polak-Ribiere (1969)

$$\beta^{(k)} = \frac{g^{(k)T} (g^{(k)} - g^{(k-1)})}{g^{(k-1)T} g^{(k-1)}} \quad , \quad \beta^{(k)} \leftarrow \max(\beta^{(k)}, 0)$$

→ 음수 제거
→ 항상 최적값 내용!

Rosenbrock에서의 Conjugate Gradient



→ 직각으로 최소값에 빠르게 계산
↓
두 방향은 Conjugate (·)
orthogonal (X)